

# Задача обучения линейного классификатора

Обучающая выборка:  $X^\ell = (x_i, y_i)_{i=1}^\ell$ ,  $x_i \in \mathbb{R}^n$ ,  $y_i \in \{-1, +1\}$

- Линейная модель классификации:

$$a(x, w) = \text{sign}\langle x, w \rangle$$


- Непрерывная аппроксимация бинарной функции потерь:

$$Q(w) = \sum_{i=1}^{\ell} [a(x_i, w)y_i < 0] \leq \sum_{i=1}^{\ell} \mathcal{L}(\langle x_i, w \rangle y_i) \rightarrow \min_w$$

Отступ (margin) объекта  $x_i$ :  $M_i(w) = \langle x_i, w \rangle y_i$

- Логарифмическая функция потерь, как функция отступа  $M$ :

$$\mathcal{L}(M) = \log(1 + e^{-M})$$



$(x_i, y_i)_{i=1}^{\ell} \sim p(x, y; w)$  — выборка независимых наблюдений.

Принцип максимума правдоподобия:

$$L(w) = \log \prod_{i=1}^{\ell} p(x_i, y_i; w) = \sum_{i=1}^{\ell} \log P(y_i|x_i; w)p(x_i) \rightarrow \max_w.$$

Вероятностная модель порождения данных с параметром  $w$ :

- $p(x)$  не зависит от параметра модели  $w$ ,
- $P(y|x; w)$  описывается линейной моделью классификации:

$$P(y_i|x_i; w) = \frac{1}{1 + \exp(-\langle x_i, w \rangle y_i)} = \sigma(\langle x_i, w \rangle y_i),$$

где  $\sigma(M) = \frac{1}{1+e^{-M}}$  — сигмоидная функция.

Тогда задачи  $Q(w) \rightarrow \min$  и  $L(w) \rightarrow \max$  эквивалентны:

$$Q(w) = \sum_{i=1}^{\ell} \log(1 + \exp(-\langle w, x_i \rangle y_i)) \rightarrow \min_w.$$

- Метод первого порядка — стохастический градиент:

$$w^{(t+1)} := w^{(t)} + \eta_t y_i x_i (1 - \sigma_i),$$

$\eta_t$  — градиентный шаг,

$\sigma_i = \sigma(\langle x_i, w \rangle y_i) = P(y_i | x_i)$  — вероятность правильной классификации  $x_i$ .

- Метод второго порядка (Ньютона-Рафсона) приводит к IRLS, Iteratively Reweighted Least Squares:

$$w^{(t+1)} := w^{(t)} + \eta_t (F^T \Lambda F)^{-1} F^T \tilde{y},$$

$F$  — матрица объекты–признаки  $\ell \times n$ ,

$\tilde{y} = (y_i(1 - \sigma_i))$  — модифицированный вектор ответов,

$\Lambda = \text{diag}((1 - \sigma_i)/\sigma_i)$  — диагональная матрица.