

$$\begin{cases} -\sum_{i=1}^{\ell} \lambda_i + \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle \rightarrow \min_{\lambda}; \\ 0 \leq \lambda_i \leq C, \quad i = 1, \dots, \ell; \\ \sum_{i=1}^{\ell} \lambda_i y_i = 0. \end{cases}$$

Решив эту задачу численно относительно λ_i ,
получаем линейный классификатор:

$$a(\mathbf{x}) = \text{sign} \left(\sum_{i=1}^{\ell} \lambda_i y_i \langle \mathbf{x}_i, \mathbf{x} \rangle - w_0 \right),$$

где $w_0 = \sum_{i=1}^{\ell} \lambda_i y_i \langle \mathbf{x}_i, \mathbf{x}_j \rangle - y_j$ для такого j , что $\lambda_j > 0$, $M_j = 1$

Определение

Объект \mathbf{x}_i называется *опорным*, если $\lambda_i \neq 0$.

$$\begin{cases} -\sum_{i=1}^{\ell} \lambda_i + \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j K(x_i, x_j) \rightarrow \min_{\lambda}; \\ 0 \leq \lambda_i \leq C, \quad i = 1, \dots, \ell; \\ \sum_{i=1}^{\ell} \lambda_i y_i = 0. \end{cases}$$

Решив эту задачу численно относительно λ_i ,
получаем линейный классификатор:

$$a(x) = \text{sign}\left(\sum_{i=1}^{\ell} \lambda_i y_i K(x_i, x) - w_0\right),$$

где $w_0 = \sum_{i=1}^{\ell} \lambda_i y_i K(x_i, x_j) - y_j$ для такого j , что $\lambda_j > 0$, $M_j = 1$

Определение

Объект x_i называется *опорным*, если $\lambda_i \neq 0$.

Определение

Функция от пары объектов $K(x, x')$ называется *ядром*, если она представима в виде скалярного произведения

$$K(x, x') = \langle \psi(x), \psi(x') \rangle$$

при некотором преобразовании $\psi: X \rightarrow H$ из пространства признаков X в новое *спрямляющее* пространство H .

Возможная интерпретация:

признак $f_i(x) = K(x_i, x)$ — это оценка близости объекта x к опорному объекту x_i . Выбирая опорные объектов, SVM осуществляет отбор признаков в линейном классификаторе

$$a(x) = \text{sign} \left(\sum_{i=1}^{\ell} \lambda_i y_i K(x_i, x) - w_0 \right).$$

Ядра в SVM расширяют линейную модель классификации:


- ❶ $K(x, x') = (\langle x, x' \rangle + 1)^d$
— полиномиальная разделяющая поверхность степени $\leq d$;
- ❷ $K(x, x') = \sigma(\langle x, x' \rangle)$
— нейронная сеть с заданной функцией активации $\sigma(z)$
(K не при всех σ является ядром);
- ❸ $K(x, x') = \text{th}(k_1 \langle x, x' \rangle - k_0), \quad k_0, k_1 \geq 0$
— нейросеть с сигмоидными функциями активации;
- ❹ $K(x, x') = \exp(-\gamma \|x - x'\|^2)$
— сеть радиальных базисных функций (RBF ядро);

Гиперплоскость в спрямляющем пространстве соответствует нелинейной разделяющей поверхности в исходном.

Примеры с различными ядрами $K(x, x')$


линейное

$$\langle x, x' \rangle$$




полиномиальное

$$(\langle x, x' \rangle + 1)^d, \quad d=3$$



гауссовское (RBF)

$$\exp(-\gamma \|x - x'\|^2)$$




Пример из Python scikits learn: <http://scikit-learn.org/dev>


SVM — аппроксимация и регуляризация эмпирического риска:

$$\sum_{i=1}^{\ell} (1 - M_i(w, w_0))_+ + \frac{1}{2C} \|w\|^2 \rightarrow \min_{w, w_0}.$$

большой C
слабая регуляризация



малый C
сильная регуляризация



Пример из Python scikits learn: <http://scikit-learn.org/dev>

Преимущества:

- Задача выпуклого квадратичного программирования имеет единственное решение.
- Выделяется множество опорных объектов.
- Имеются эффективные численные методы для SVM.
- Изящное обобщение на нелинейные классификаторы.

Недостатки:

- Опорными объектами могут становиться выбросы.
- Нет отбора признаков в исходном пространстве X .
- Приходится подбирать константу C .