

## Дано:

множество объектов  $X$ , множество классов  $Y$ ;

$X^\ell = \left\{ \begin{matrix} x_1, \dots, x_\ell \\ y_1, \dots, y_\ell \end{matrix} \right\}$  — размеченная выборка (labeled data);

$X^k = \{x_{\ell+1}, \dots, x_{\ell+k}\}$  — неразмеченная выборка (unlabeled data).

## Два варианта постановки задачи:


- *Частичное обучение* (semi-supervised learning):  
построить алгоритм классификации  $a: X \rightarrow Y$ .
- *Трансдуктивное обучение* (transductive learning):  
зная **все**  $\{x_{\ell+1}, \dots, x_{\ell+k}\}$ , получить метки  $\{y_{\ell+1}, \dots, y_{\ell+k}\}$ .

## Типичные приложения:


классификация и каталогизация текстов, изображений, и т. п.

**Пример 1.** плотности классов, восстановленные:

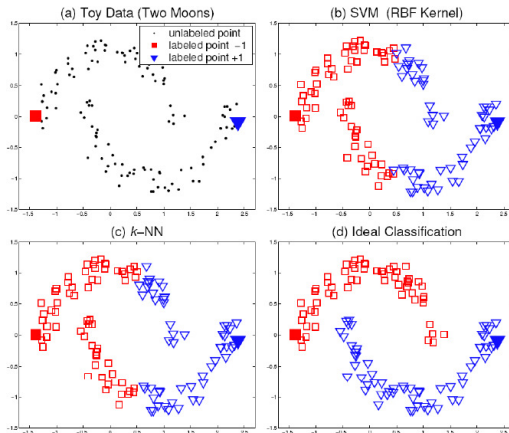
по размеченным данным  $X^\ell$




по полным данным  $X^{\ell+k}$



## Пример 2. Методы классификации не учитывают кластерную структуру неразмеченных данных



**Пример 3.** Методы кластеризации не учитывают приоритетность разметки.



Пусть  $\mu: X^\ell \rightarrow a$  — произвольный метод обучения;  
классификаторы имеют вид  $a(x) = \arg \max_{y \in Y} \Gamma_y(x)$ ;

Псевдоотступ — степень уверенности классификации  $a_i = a(x_i)$ :

$$M_i(a) = \Gamma_{a_i}(x_i) - \max_{y \in Y \setminus a_i} \Gamma_y(x_i).$$

**Алгоритм self-training** — обёртка (wrapper) над методом  $\mu$ :

- 1:  $Z := X^\ell$ ;
- 2: **пока**  $|Z| < \ell + k$
- 3:    $a := \mu(Z)$ ;
- 4:    $\Delta := \{x_i \in X^k \setminus Z \mid M_i(a) \geq M_0\}$ ;
- 5:    $y_i := a(x_i)$  для всех  $x_i \in \Delta$ ;
- 6:    $Z := Z \cup \Delta$ ;

$M_0$  можно определять, например, из условия  $|\Delta| = 0.05 k$

Пусть  $\mu_1: X^\ell \rightarrow a_1$ ,  $\mu_2: X^\ell \rightarrow a_2$  — два существенно различных метода обучения, использующих

- либо разные наборы признаков;
- либо разные парадигмы обучения (inductive bias);
- либо разные источники данных  $X_1^{\ell_1}$ ,  $X_2^{\ell_2}$ .

1:  $Z_1 := X_1^{\ell_1}$ ;  $Z_2 := X_2^{\ell_2}$ ;

2: **пока**  $|Z_1 \cup Z_2| < \ell + k$

3:  $a_1 := \mu_1(Z_1)$ ;  $\Delta_1 := \{x_i \in X^k \setminus Z_1 \setminus Z_2 \mid M_i(a_1) \geq M_{01}\}$ ;

4:  $y_i := a(x_i)$  для всех  $x_i \in \Delta_1$ ;

5:  $Z_2 := Z_2 \cup \Delta_1$ ;

6:  $a_2 := \mu_2(Z_2)$ ;  $\Delta_2 := \{x_i \in X^k \setminus Z_1 \setminus Z_2 \mid M_i(a_2) \geq M_{02}\}$ ;

7:  $y_i := a(x_i)$  для всех  $x_i \in \Delta_2$ ;

8:  $Z_1 := Z_1 \cup \Delta_2$ ;

Пусть  $\mu_t: X^\ell \rightarrow a_t$  — разные методы обучения,  $t = 1, \dots, T$ .

**Алгоритм co-learning** — это self-training для композиции — простого голосования базовых алгоритмов  $a_1, \dots, a_T$ :

$$a(x) = \arg \max_{y \in Y} \Gamma_y(x), \quad \Gamma_y(x_i) = \sum_{t=1}^T [a_t(x_i) = y].$$

тогда  $M_i(a)$  — степень уверенности классификации  $a(x_i)$ .

- 1:  $Z := X^\ell$ ;
- 2: **пока**  $|Z| < \ell + k$
- 3:    $a := \mu(Z)$ ;
- 4:    $\Delta := \{x_i \in X^k \setminus Z \mid M_i(a) \geq M_0\}$ ;
- 5:    $y_i := a(x_i)$  для всех  $x_i \in \Delta$ ;
- 6:    $Z := Z \cup \Delta$ ;

- Задача SSL занимает промежуточное положение между классификацией и кластеризацией, но не сводится к ним.
- Простые методы-обёртки требуют многократного обучения, что вычислительно неэффективно.
- *Методы кластеризации* легко адаптируются к SSL путём введения ограничений (constrained clustering), но, как правило, вычислительно трудоёмки.
- *Методы классификации* адаптируются сложнее, но приводят к более эффективному частичному обучению.